# Lab3 Part2 实验汇报

## 动态测试优化与结果总结

我的刀盾队

Android Privacy Detection Software

2026-05-09

# 目录


1. 实验目标与背景
2. 主要优化内容
3. 实验结果
4. 应用具体介绍
5. 结论与计划

# 实验目标

- 验证应用内个人信息查阅与管理相关路径的可达性与可用性。
- 构建可复现、可解释、可对比的 Part2 动态测试结论。
- 在不改动测试范围的前提下，重点提升稳定性、命中率与报告可信度。

# 初始问题

- 导航不稳定，常出现首步未命中或中途中断。
- 同一功能在不同应用中名称差异大，语义映射困难。
- 路径描述中存在不可自动执行表达，影响用例质量。
- 自动化与非自动化结果混合，统计口径不清晰。
- 失败原因未分层，难以定位是测试问题还是产品能力问题。

# Part2 工程 Pipeline 与优化思路

**当前工程 Pipeline（端到端）**

- **输入层**：Part1 输出 `audit_processed.csv`（path_text / right_types / channels）。
- **用例层**：进行路径规范化、去重、优先级排序，生成 `test_cases.json`。
- **执行层**：调度 `Appium + UIAutomator + Navigator + Service` 执行动态测试。
- **评估层**：结构化规则 + LLM 评估（可寻性/功能性/效率/一致性）输出 PASS/FAIL/SKIP。
- **报告层**：生成 per-app 结果、聚合统计与失败归因分桶。

**实现细节与优化主线**

- **导航鲁棒性**：多策略定位（id/desc/xpath/text）+ 跨页兜底（当前页 → 个人页 → 侧边栏）。
- **语义适配**：别名映射（中英同义词）+ 并列路径 OR 语义（`tap_any`）+ 页面变化判定。
- **稳定性**：起始页归一、登录态识别、就绪检测与重试、等待时长精简。
- **可解释性**：自动化/非自动化分开统计，FAIL 分层为导航未达/功能未命中/产品能力缺口。

# Part2 Pipeline 流程图

**Part1 审计输出**

⇓

**用例生成与清洗**

path_text 规范化 + 去重 + 优先级

⇓

**动态执行引擎**

Runner + Navigator + UIAutomator + Service

⇓

**多策略导航**

id/desc/xpath/text + 跨页兜底 + OR 并列路径

⇓

**规则 + LLM 联合评估**

PASS/FAIL/SKIP + 可寻性/功能性/效率/一致性

⇓

**报告与归因输出**

自动化/非自动化分流 + 失败分层归因

# 优化主线

- **导航层优化**：多级定位与跨页面兜底，降低单点失败影响。
- **语义适配优化**：别名扩展与并列路径处理，提升文案兼容性。
- **用例生成优化**：路径规范化、去重和优先级排序，提高可执行率。
- **执行稳定性优化**：等待与重试策略调整，减少假失败。
- **结果解释优化**：自动化/非自动化分流统计，失败分层归因。

# 优化后评估口径

- 覆盖场景：Part2 Access（查阅/访问）相关路径。
- 结果维度：PASS / FAIL / SKIP / ERROR。
- 质量维度：可发现性、功能可达性、效率、一致性与综合可用性。
- 解释维度：导航未达、功能未命中、产品能力缺口、其他。
- 原则：自动化与需人工验证渠道分开统计。

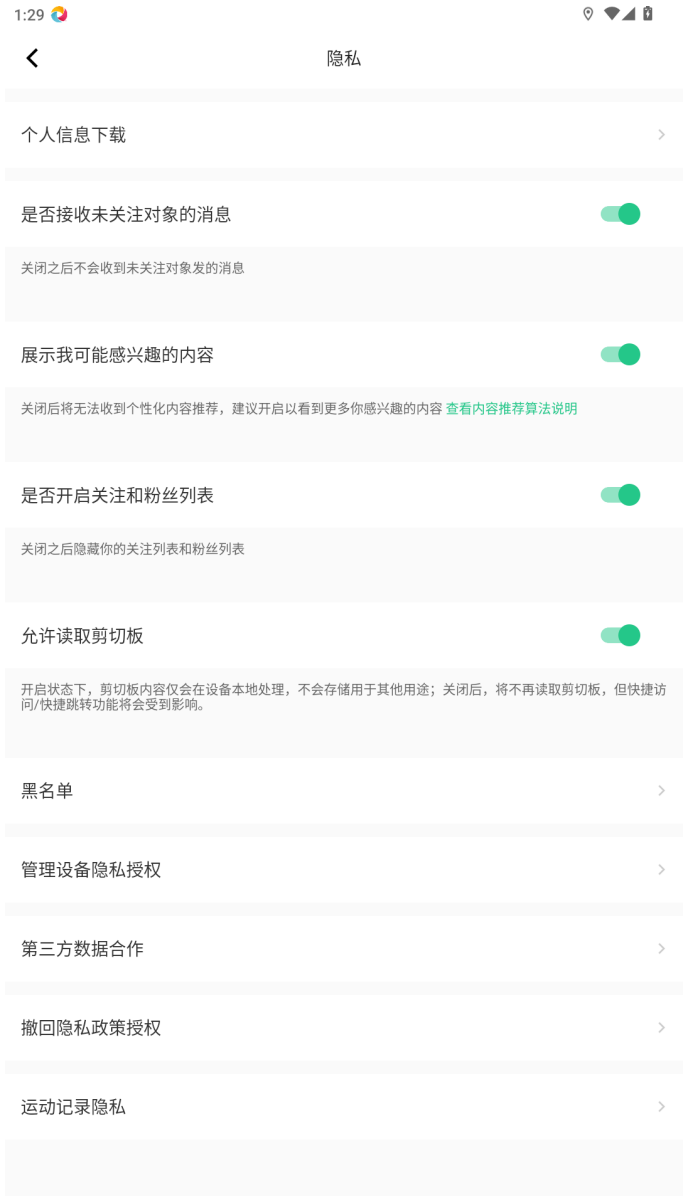
# 结果总览（上）

| 应用 | 用例 | PASS | FAIL | SKIP | 通过率 | 新评分 | |
|---|---|---|---|---|---|---|---|
| Keep | 9 | 5 | 1 | 3 | 55.6% | 47.5 | |
| 小红书 | 4 | 3 | 1 | 0 | 75.0% | 27.6 | |
| 支付宝 | 3 | 1 | 1 | 1 | 33.3% | 17.1 | |
| LOFTER | 1 | 0 | 0 | 1 | 0.0% | 13.7 | |
| 智联招聘 | 10 | 3 | 3 | 4 | 30.0% | 34.9 | |
| 好大夫医生版 | 2 | 0 | 0 | 2 | 0.0% | 25.6 | |
| 小荷健康 | 1 | 0 | 0 | 1 | 0.0% | 13.7 | |
| 东方财富 | 1 | 0 | 0 | 1 | 0.0% | 13.7 | |
| 世纪佳缘 | 1 | 0 | 0 | 1 | 0.0% | 13.7 | |

评分函数：$S = \max\left(0,\ 100 \cdot \frac{N}{N+5} \cdot \left(1 - \left(\frac{F}{N}\right)^{0.7}\right) - 3 \cdot \mathbf{1}_{K>0}\right)$，其中 $N$ 为总样例数、$F$ 为 FAIL 数、$K$ 为 SKIP 数。

# Keep：具体结果说明

- PASS 5 / FAIL 1 / SKIP 3。
- 关键 FAIL：Keep-access-0232（app_ui）。
- 路径执行：我 -> 设置 -> 隐私（隐私设置）。
- 评分：findability=3，functionality=1，efficiency=1，consistency=1，usability=32.0。
- LLM 判定：已进入“隐私”页，但缺少“设置/访问/更正隐私信息”功能入口，与政策描述不符。
- 归因：规则/模型判定未通过；替代通道未发现明确入口。
- 耗时：202.31 秒。




Keep-access-0232 截图

# 小红书：具体结果说明

- PASS 3 / FAIL 1。
- 样例 1（PASS）：小红书-access-0254，路径“我-> 编辑资料”可达，可完成个人资料查看/修改。
- 样例 2（PASS）：小红书-access-0256，路径“我-> 隐私设置”可达，可完成隐私设置。
- 样例 3（FAIL）：小红书-access-0255，已进入“账号与安全”页面，但目标能力不匹配，归类“路径不匹配”。
- 结论：入口可达性明显改善，但深层能力页的一致性仍是主要瓶颈。

# 支付宝：具体结果说明

- PASS 1 / FAIL 0 / SKIP 1。
- 样例 1（PASS）：支付宝-access-0180，日志显示“我的-> 编辑资料”可达，可完成个人资料查看/修改。
- 样例 2（FAIL）：支付宝-access-0174，日志显示“未找到身份/账单/账户信息入口”，归类“我没找到路径”。
- 样例 3（SKIP）：支付宝-access-0009，政策描述为“本政策介绍的方式”，自动化渠道信息不足，转人工核验。
- 结论：当前未通过主要来自路径命中问题，不等价于产品侧能力缺失。

# LOFTER：具体结果说明

- PASS 0 / FAIL 0 / SKIP 1。
- 样例 1（SKIP）：LOFTER-access-0181，客服联系渠道场景，需人工核验。
- 结论：本轮 LOFTER 主要为人工渠道验证场景，自动化结果样本有限。

# 智联招聘：具体结果说明

- PASS 3 / FAIL 3 / SKIP 4。
- 样例 1（PASS）：智联招聘-access-0278，"我的-> 隐私中心"链路可达。
- 样例 2（FAIL）：智联招聘-access-0280，未找到导出入口。
- 样例 3（SKIP）：智联招聘-access-0067，渠道信息不足，政策原文："为便于招聘者... 提供将求职者简历下载到本地的功能。"但没有检查到明显途径，需人工核验。
- 样例 4（FAIL）：智联招聘-access-0236，未提取到网页端有效 URL，需人工确认网页渠道。
- 结论：智联招聘当前自动化覆盖受入口可达性和渠道类型限制较大。

# 好大夫医生版：具体结果说明

- PASS 0 / FAIL 0 / SKIP 2。
- 样例 1（SKIP）：好大夫医生版-access-0257，未能成功登录注册，需人工确认网页渠道。（需要提供有效证件才能成为合法用户）
- 样例 2（SKIP）：好大夫医生版-access-0260，未能成功访问 website_url_lnk，需人工确认网页渠道。
- 结论：好大夫医生版需要提供有效证件才能成为合法用户，因此无法自动验证。

# 小荷健康：具体结果说明

- PASS 0 / FAIL 0 / SKIP 1。
- 样例 1（SKIP）：小荷健康-access-0244，客服/联系渠道类验证，需人工核验。
- 结论：本轮小荷健康为人工渠道验证样本，自动化结果暂不充分。

# 本轮优化成效

- 提升为“可解释地跑”，可以看到 AI 基于对 XML 元素的判断，在应用界面的操作符合用户直觉。
- 导航鲁棒性提升，尤其在个人页与设置页相关链路上更稳定。
- 报告结构清晰，自动化结论与人工复核结论分离明确。
- 失败原因可分层定位，支持后续定向优化。

# 后续改进计划

- 强化首屏清理与起始状态归一，降低首步失败率。
- 增强深层页面探测能力，补充滚动与多快照联合验证。
- 完善应用级能力基线，降低跨应用评估波动。
- 建立非自动化渠道标准记录模板，补齐最终结论链路。

# 汇报总结

Part2 通过导航稳定性、语义对齐与分层归因三条主线优化，
已将动态测试从单点尝试升级为可复现、可解释、可对比的实验体系，
为后续规模化评估奠定基础。

感谢聆听！