隐私政策切句与个信法相关句筛选

Lab 2-3：Data Safety 衔接与 WEEK_4 流水线实验汇报

李禹江，张博涵，蒋兴宇

我的刀盾队

2026 年 4 月 6 日

目录

1. 实验目标
2. 实验环境
3. 实验过程
4. 实验结果
5. 可能的提升方向

实验目标（对齐课程讲义 Lab 2-3）

- 将各应用隐私政策**切分为句子**，保留 doc_id、sent_index，便于回溯原文位置。
- 对每句做**二分类**：是否与**个人信息的处理与利用**相关（收集、使用、存储、共享、跨境、安全、权利响应等）。
- 输出 sentences.jsonl、stats.json 及与 WEEK_3 2-2 同列的 sentences_week3_2_2.csv，服务后续**人工抽检**与 run_audit 衔接。
- 附带**关键词弱信号** keyword_hint，用于粗排序与对照，**不替代**模型结论。

实验环境

- **操作系统**：Windows 10/11；Shell：PowerShell。
- **Python**：3.10+）。
- **核心依赖**：`pandas`）、`matplotlib`、`ollama`。

实验流程概览

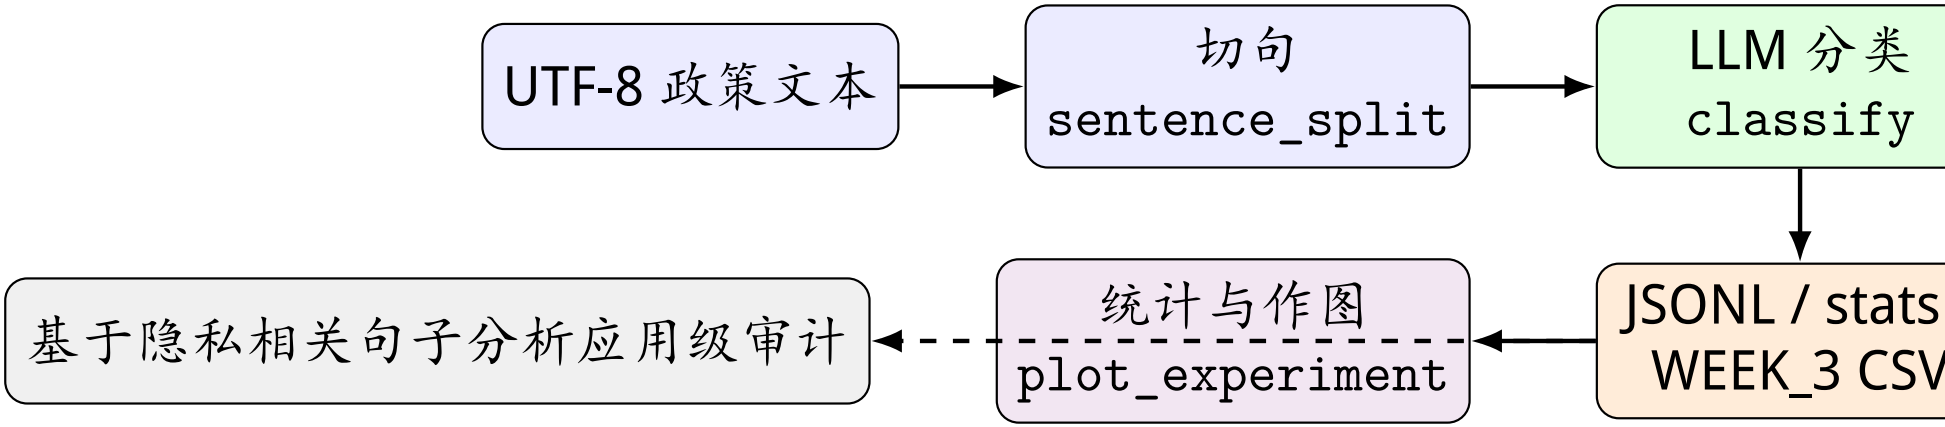
UTF-8 政策文本
切句
sentence_split
LLM 分类
classify
JSONL / stats
WEEK_3 CSV
统计与作图
plot_experiment
基于隐私相关句子分析应用级审计

五款应用与数据来源

- **对象应用：小红书、LOFTER、Blued 极速版、世纪佳缘、Soul。**
- **处理内容：**各应用隐私政策全文 → 切句 → 句子级「个人信息处理相关」二分类 + 规则 `keyword_hint`。

五款应用分项结果（完整指标）

应用	总句	相关	无关	模型相关占比	关键词占比
小红书	296	230	65	77.70%	55.74%
LOFTER	227	198	29	87.22%	59.91%
Blued 极速版	192	171	21	89.06%	63.54%
世纪佳缘	323	286	37	88.54%	63.16%
Soul	347	293	54	84.44%	66.57%
合计	**1385**	—	—	**≈85.1%**	—

- 「模型相关占比」：分应用为 **相关/总句**；合计为五应用相关句之和除以总句数，即 **1178/1385**。

数据规模：五款应用切句数量

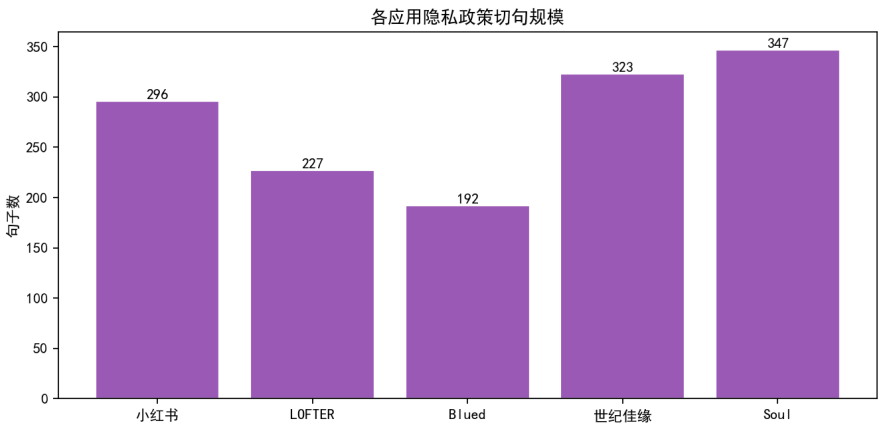

- 全量流水线共 **1385** 句。
- 规模最大：**Soul**（347 句）；最小：**Blued 极速版**（192 句）。

应用	句数
小红书	296
LOFTER	227
Blued 极速版	192
世纪佳缘	323
Soul	347
合计	**1385**

关键词弱信号：keyword_hint 规则

对每条句子用正则子串匹配；任一词干出现则 keyword_hint=true，统计入绿色柱的「命中占比」。

```
_HINT_RE: Pattern[str] = re.compile(
    r"(个人信息|个人敏感信息|隐私|收集|处理|使用|存储|保存|共享|转让|"
    r"披露|委托|跨境|第三方|SDK|权限|设备信息|位置|通讯录|相册|相机|"
    r"麦克风|日志|Cookie|标识符|IMEI|OAID|IDFA|MAC|IP|账号|手机号|"
    r"实名|注销|撤回|删除|更正|复制|查阅|未成年人|儿童|敏感)"
)
```

规则弱信号 vs 模型「个信相关」占比

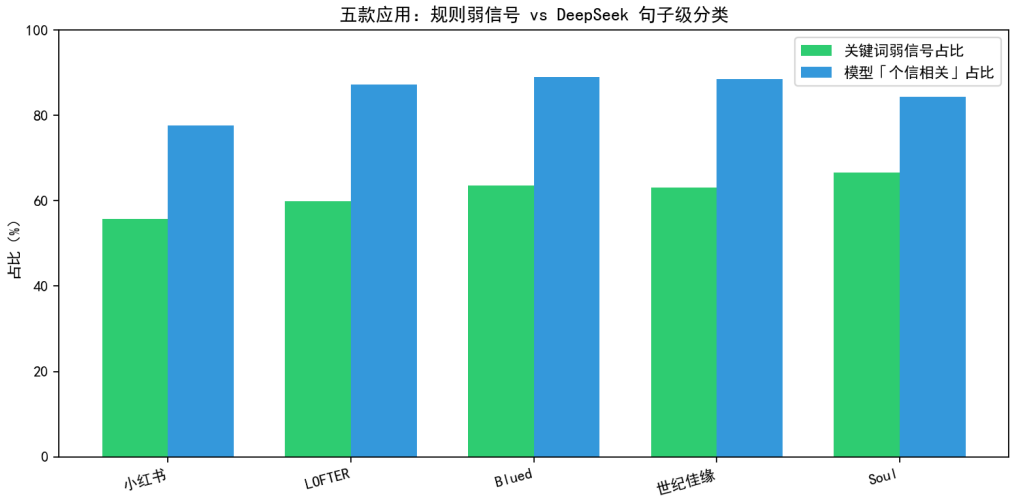

- 绿色柱：keyword_hint 命中占比（词干正则见「keyword_hint 规则」帧）；蓝色柱：模型判「相关」占全句比例。
- 模型占比**系统高于**关键词：弱规则无法覆盖全部表述，LLM 可补全「无关键词仍属个信处理」的句子。
- 跨应用差异反映政策写法与非隐私段落比例不同，可用于**分层抽检**。

模型判「相关」的句数（绝对量）

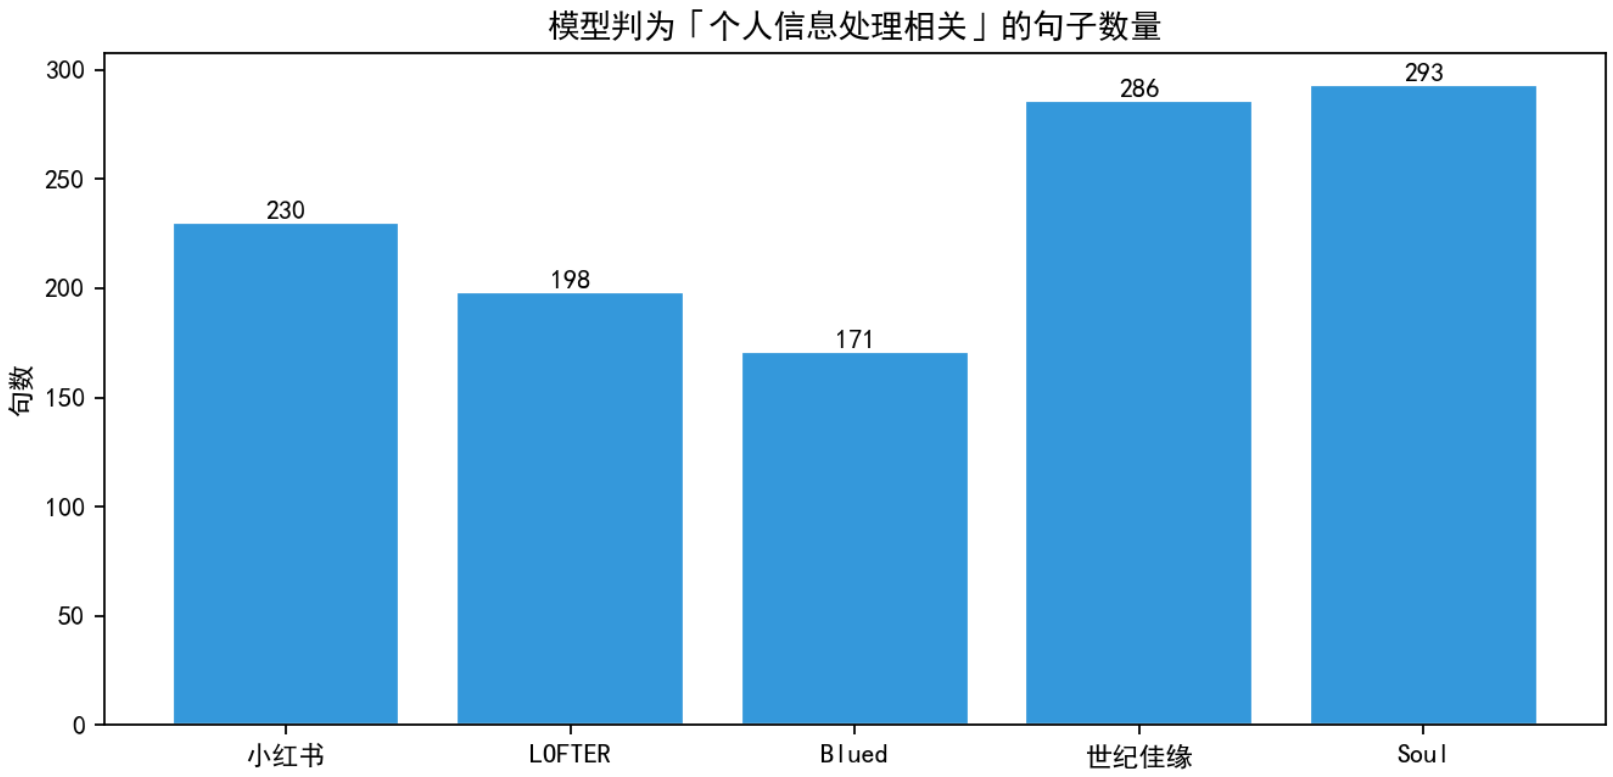

- 五应用合计：模型判「相关」**1178** 句，占全量 **1178/1385 ≈ 85.1%**。

典型案例：Soul 关键词 / 模型计数与句长分布

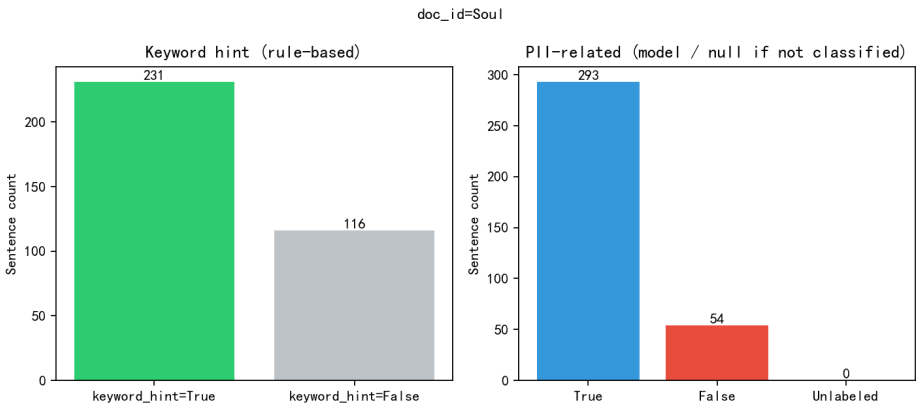

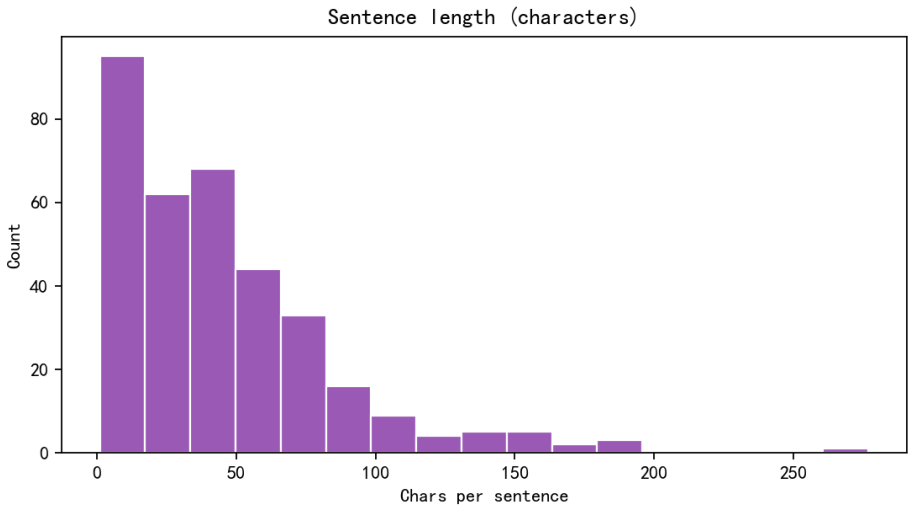

左：规则与模型分类句数；右：句长直方图（字符数），用于观察切句粒度与长句抽检需求。

拓展：句子表 + WEEK_3 audit 抽样（每应用前 20 行）

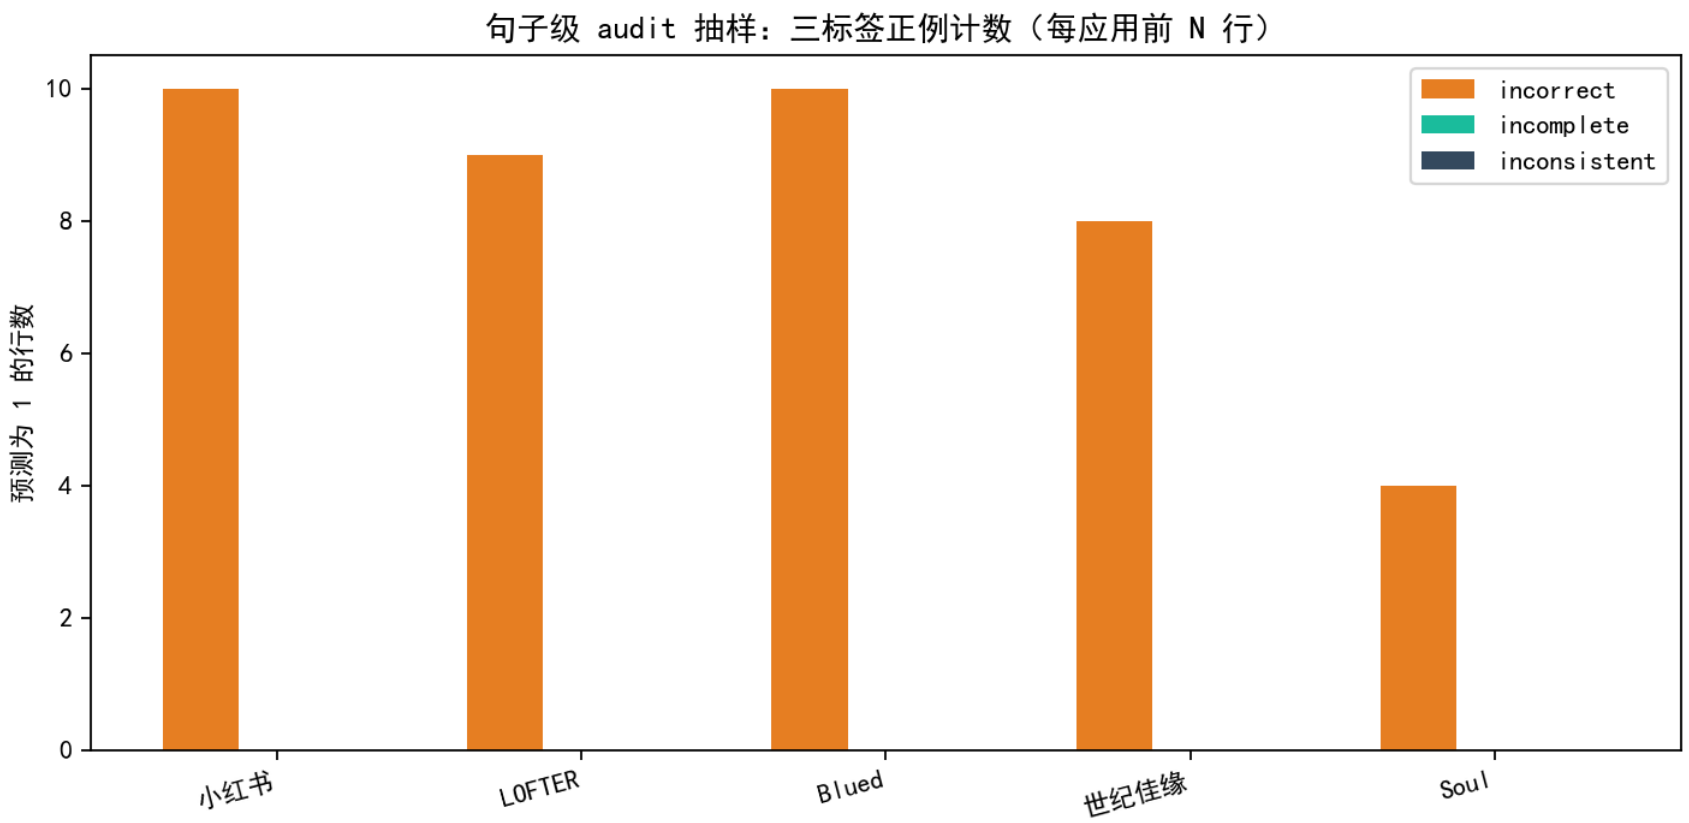

- 横轴为各应用，纵轴为预测标签为 1 的行数。
- **注意**：句级 CSV 中 Data Safety 多为占位，与「完整 DS vs 全文 PP」应用级审计不等价，结果仅供流程演示与误例分析。

指标汇总表（摘自各应用 stats.json）

应用	总句数	模型相关占比	关键词占比
小红书	296	77.70%	55.74%
LOFTER	227	87.22%	59.91%
Blued 极速版	192	89.06%	63.54%
世纪佳缘	323	88.54%	63.16%
Soul	347	84.44%	66.57%

可能的提升方向

- **数据质量**：固定政策版本日期字段，便于合规追溯。
- **提示与模型**：细化边界句定义（法律援引、口号句是否算「相关」）；对比 Qwen/Ollama 本地模型与 DeepSeek，做一致性抽检。
- **弱监督与评测**：分层随机抽样算人工一致率；发布 10–20 条**标注指南**稳定标签语义。
- **讲义拓展**：对 `sentences.jsonl` 做句向量 + UMAP/HDBSCAN 聚类，辅助主题分布与难例挖掘（非必做）。
- **工程化**：高价值子集按 `pii_related` 与 `keyword_hint` 联合排序后送标。

感谢聆听！