隐私政策句级分析一体化流水线

聚类、少样本学习、人工送标与 Data Safety 句级审计

李禹江，张博涵，蒋兴宇

我的刀盾队

2026-04-13

目录

1. 实验目的
2. 实验环境
3. 实验内容
4. 实验结果

实验目的

- **句级结构化**：将多款应用隐私政策**切分为句子**，为每句赋予**文档与句序号**，便于检索、审计与可视化。
- **个信相关判别**：对每句做**二分类**（是否与**个人信息的处理与利用**实质相关），并用**规则弱信号**（关键词等）与模型结果对照。
- **Data Safety 风格句级审计**：在「披露侧—政策句」对比框架下输出 **incorrect / incomplete / inconsistent** 三标签，支撑合规差异分析。
- **主题维度分析**：句向量聚类 + 与个保法 22 项参考段的相似度，辅助**主题分布**与**政策—法条**对照。
- **人机协同**：对高优先级句子**送标**，由人在统一界面中写标签与备注；**人机分歧**可回收到**少样本示例库**，迭代改进分类边界。

实验环境

- **系统**：Windows 10/11。
- **软件栈**：Python 3.10+；中文句向量嵌入（BGE 系）；降维（UMAP）、密度聚类（HDBSCAN）；可视化与批处理脚本。
- **嵌入与聚类**：采用 FlagEmbedding 管线加载 **BAAI/bge-small-zh-v1.5**，用于句向量、法参考段向量及后续降维聚类。
- **数据**：五款应用的隐私政策**中文原文**（UTF-8）：小红书、LOFTER、Blued 极速版、世纪佳缘、Soul。

实验流程总览（端到端）

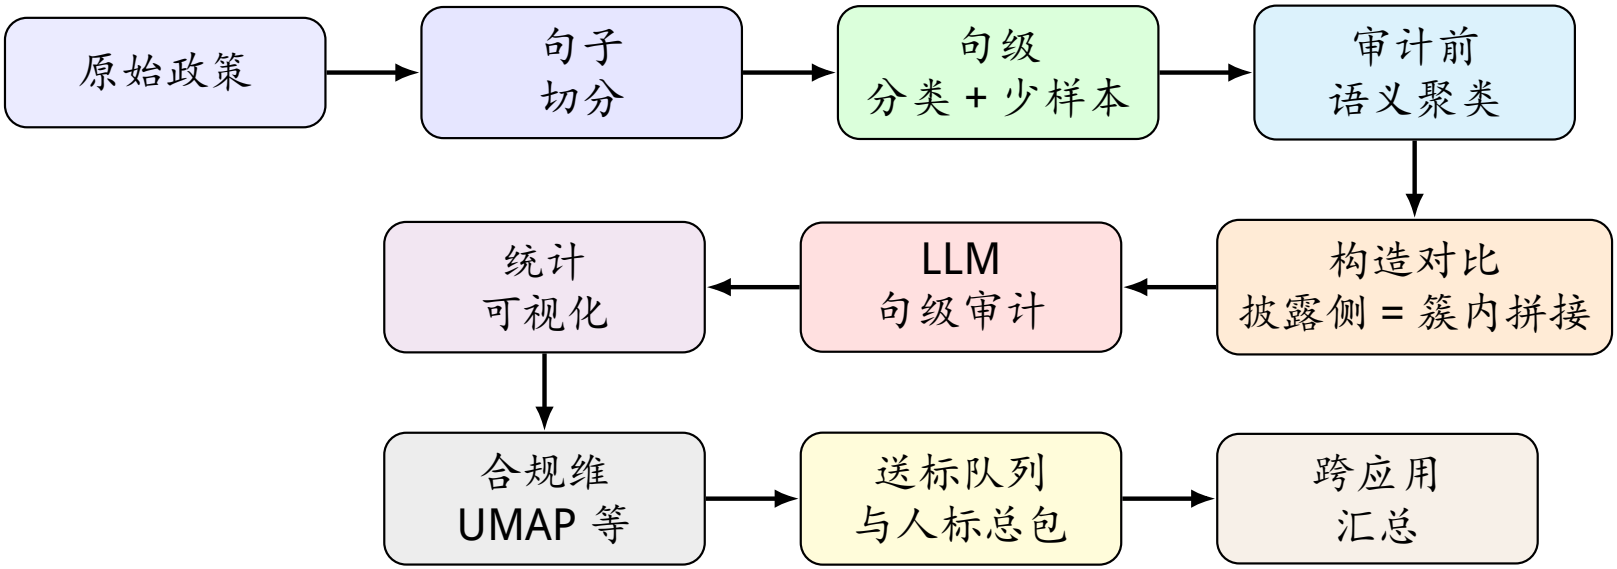
原始政策
句子
切分
句级
分类 + 少样本
审计前
语义聚类
构造对比
披露侧 = 簇内拼接
LLM
句级审计
统计
可视化
合规维
UMAP 等
送标队列
与人标总包
跨应用
汇总

实验内容：审计前聚类（特殊优化之一）

- **动机**：若**单独切句**，各句之间**语义联系缺失**，模型难以把握上下文，容易出现**大量误报和漏报**。
- **做法**：先把**所有句子**做成向量，再按语义远近**自动分成若干簇**；审计每一句时，把**同簇其它句拼成披露侧「背景段落」**，与**当前政策句**成对送入模型对比，相当于**带上邻句语义**，而不是孤立单句。

实验内容：少样本（Few-shot）机制

- **做法**：在句级「是否与个信处理实质相关」的提示词中，**拼接若干标注好的正反例**（句文本 + 是/否），让模型对齐边界。
- **规模控制**：每次调用限制示例条数上限，避免提示过长、噪声过多。
- **与人工闭环**：送标形成人机标签后，从**分歧句**抽取新示例**合并进示例库**，下一轮分类自动带上，实现迭代收紧。

实验内容：人工送标

- **排序规则**：综合**模型判定**、**规则弱信号**与**置信度**对句子排序，优先把「边界难例」送进标注队列。
- **截断策略**：每应用只取队列前 **30** 条进入本轮人工任务，控制标注成本。
- **标注形态**：每条保留**模型侧结果**与**人工侧字段**（是否相关、备注、标注时间等），可整包编辑，也可拆成多人分表再**合并**、**校验**、**统计一致率**。

实验内容：其它工程要点

- **配置与日志编码**：汇总配置使用 UTF-8 **无 BOM**，避免下游解析异常；控制台建议开启 UTF-8，减少中文与 JSON 混排时的乱码。
- **审计与可视化衔接**：若某次审计未跑满全句，合规可视化阶段对**未审到的尾部**按「无审计标签」补齐，避免维表错位、流程中断。
- **中文字体**：统计图与 UMAP 在 Windows 上**显式注册中文字体**，避免图内中文缺字、方框。
- **批处理**：整条流水线由脚本一键串联，减少手工拷贝中间结果。

数据规模与实验设置

- **应用数**：5；**总句数**：**1385**。
- **分类与审计**：对全部句子做句级分类；审计阶段**不设条数上限**，每句均产出三标签（**审计为全量**）。
- **少样本**：句级分类**启用**正反例注入，每次最多 **12** 条示例。
- **审计前聚类**：**开启**，披露侧采用同簇句拼接背景。
- **送标**：每应用取优先级最高的 **30** 条进入人工队列（**送标为抽样；审计统计不为抽样**）。

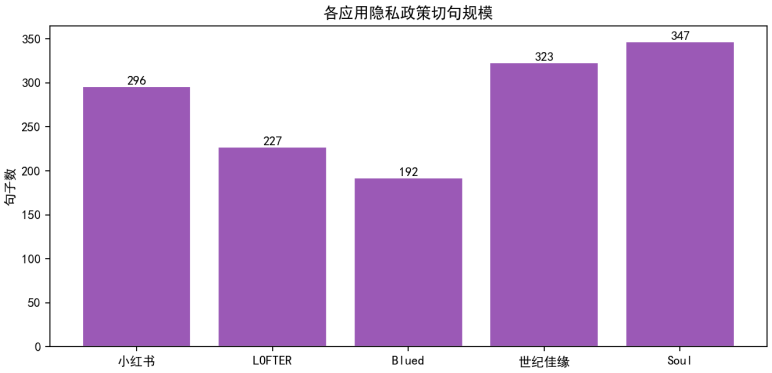

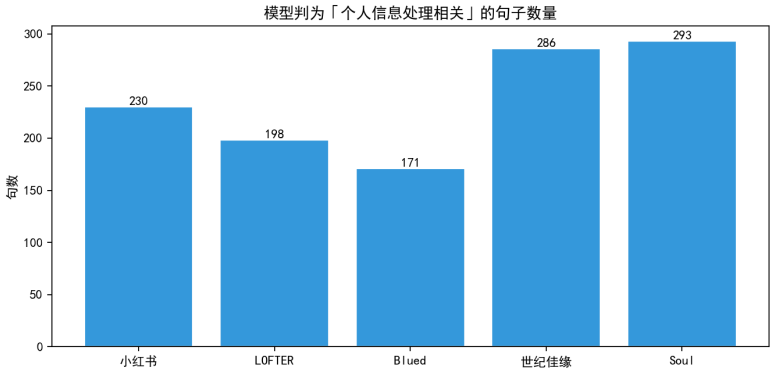

句级审计三标签汇总（大模型全量，共 1385 句）

应用	句数	incorrect 正例	incomplete 正例	inconsistent 正例	三标签合计
Blued 极速版	192	51	3	4	58
LOFTER	227	44	5	1	50
Soul	347	87	11	6	104
世纪佳缘	323	53	2	0	55
小红书	296	109	9	2	120
合计	**1385**	**344**	**30**	**13**	**387**

- 占全库比例（近似）：**incorrect 24.8%**，**incomplete 2.2%**，**inconsistent 0.9%**（三标签可同句为 1，故分行加总可大于句数）。
- **小红书** incorrect 计数相对突出；**世纪佳缘**无 inconsistent 正例。

可视化：规则 vs 模型占比（历史汇总图）

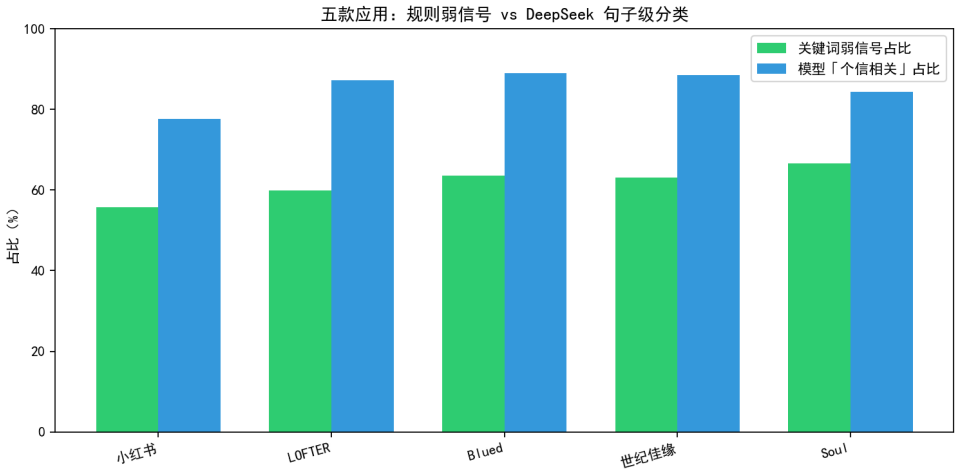

- 绿柱：**规则弱信号**命中占比；蓝柱：**模型判定为个信相关**占比。
- 用于观察**弱规则与 LLM** 的差异，辅助送标优先级解释。

可视化：以 Soul 为例——分类与句长

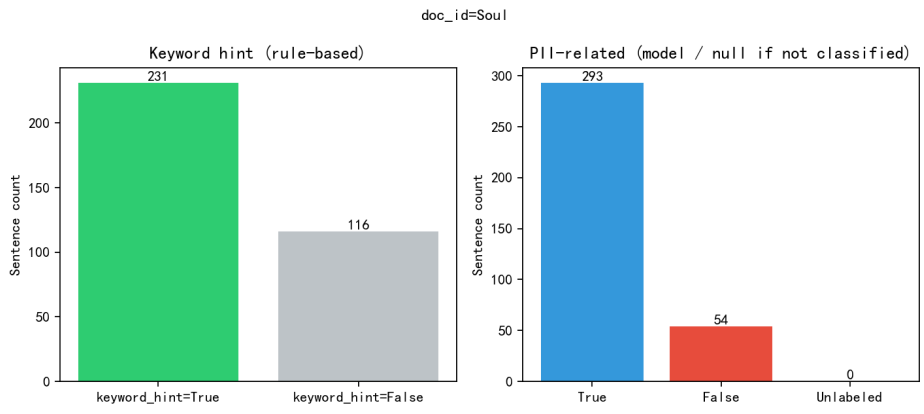

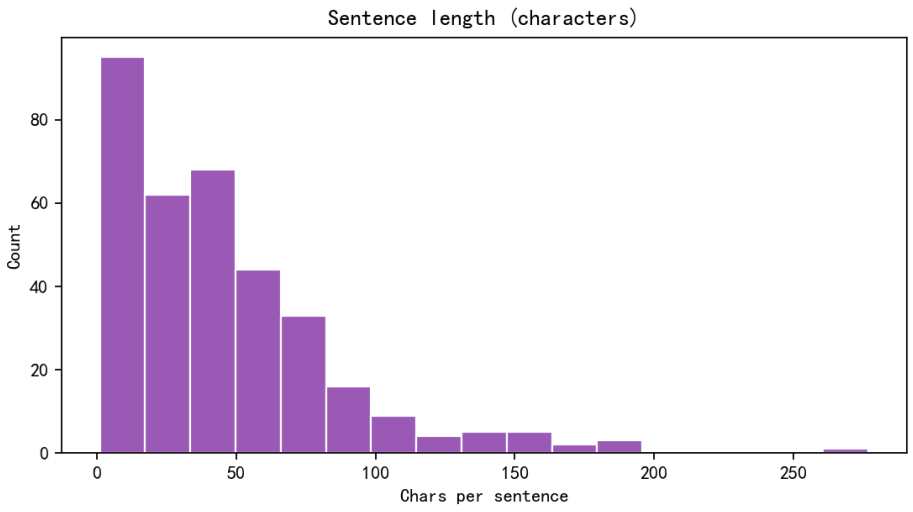

分析标准：核心内容要求（1-8）

序号	内容要求	对应法条	规范要点
一、隐私政策的核心内容要求（必须告知的事项）			
1	个人信息处理者的身份与联系方式	第十七条第一款第一项	明确运营主体，并提供有效联系方式
2	个人信息的处理目的、方式、种类与保存期限	第十七条第一款第二项	目的具体明确、方式清晰、种类逐项列出、保存期限最短必要
3	用户行使权利的方式和程序	第十七条第一款第三项	明确告知如何行使各项权利，提供便捷申请渠道
4	法律、行政法规规定的其他事项	第十七条第一款第四项	关注配套法规（《网络安全法》《数据安全法》等）
5	查阅复制权行使方式	第四十五条	告知如何查阅、复制个人信息，提供便捷申请渠道
6	更正补充权行使方式	第四十六条	告知如何申请更正或补充不准确、不完整的个人信息
7	删除权行使方式	第四十七条	告知删除情形及具体申请路径、处理时限
8	撤回同意权行使方式	第十五条	撤回渠道应与同意方式同等便捷，不影响其他功能

分析标准：特定情形额外告知（9-16）

序号	内容要求	对应法条	规范要点
	二、针对特定情形或信息的额外告知要求		
9	处理敏感个人信息	第三十条	告知处理必要性及对个人权益的影响
10	向境外提供个人信息	第三十九条	告知境外接收方信息，并取得单独同意
11	不满 14 周岁未成年人信息	第三十一条	制定专门规则，取得监护人同意
12	委托处理、共同处理、因合并/分立转移信息	第二十一、二十二、二十三条	告知接收方信息，包括名称、联系方式、处理目的等
13	自动化决策（如个性化推荐）	第二十四条	保证透明度与公平公正，提供非个性化选项
14	公开披露个人信息	第二十五条	原则上应取得单独同意，告知目的、种类及影响
15	已公开信息处理规则	第二十七条	遵循合理性原则，不得超出合理范围
16	数据泄露应急措施	第五十七条（建议）	明确泄露通知流程，包括通知方式、时限及补救措施

分析标准：格式与表述规范（17-22）

序号	内容要求	对应法条	规范要点
	三、隐私政策的格式与表述规范		
17	显著清晰，易于理解	第十七条	语言平实易懂，展示方式显著，结构清晰
18	真实、准确、完整	第十七条	内容与实际处理实践完全一致
19	公开且便于查阅保存	第十七条第三款	长期公开在易于访问位置，提供离线保存选项
20	获得同意的规范	第十四条、第二十九条	自愿明确作出同意，特定情形需单独同意
21	与产品功能界面联动	第七条	隐私政策条款与 App 内权限申请弹窗等保持一致
22	撤回同意便捷性	第十五条	撤回渠道与获取同意方式同等便捷

可视化：Soul 一个信相关 × 规则（UMAP）与 22 项着色

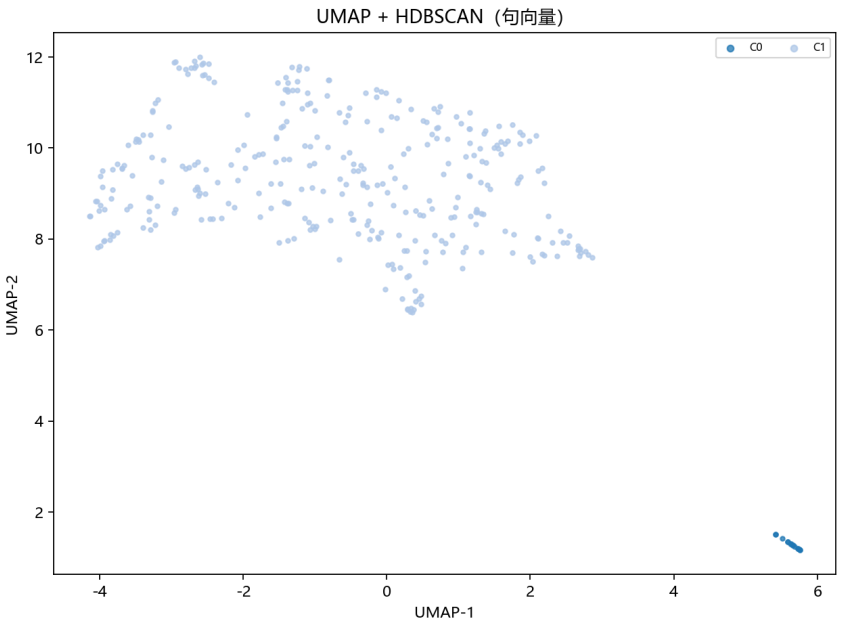

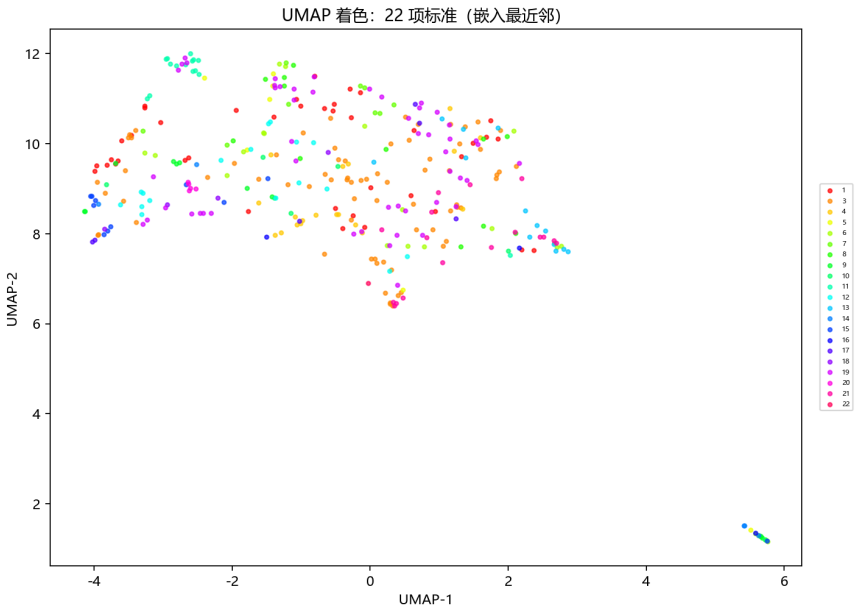

左：原 HDBSCAN 密度聚类图位置，改为同一 UMAP 上按**模型个信相关 × 规则弱信号**四象限着色（替代无监督簇）；右：按 22 项中**余弦相似度最大**的一项着色。

可视化：Blued 极速版—UMAP 与密度聚类、22 项着色

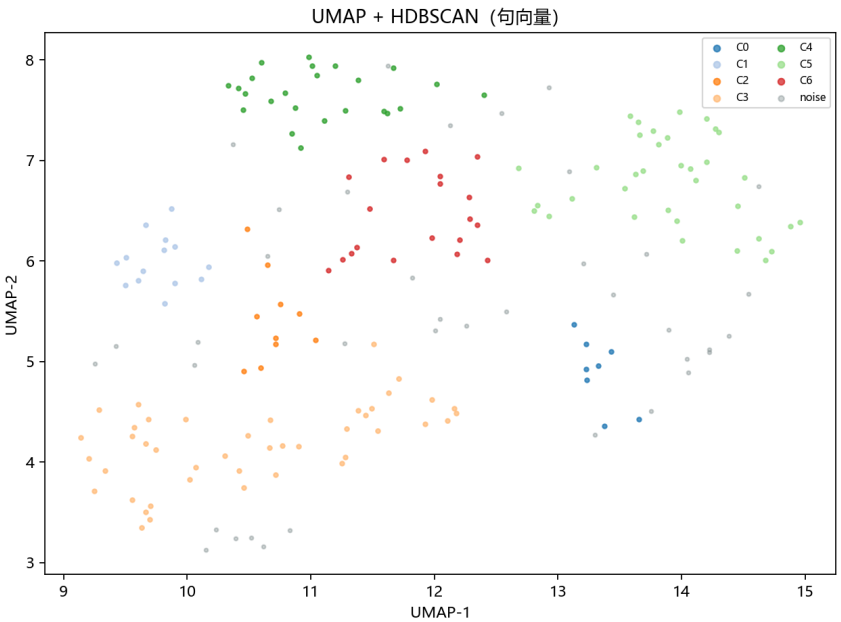

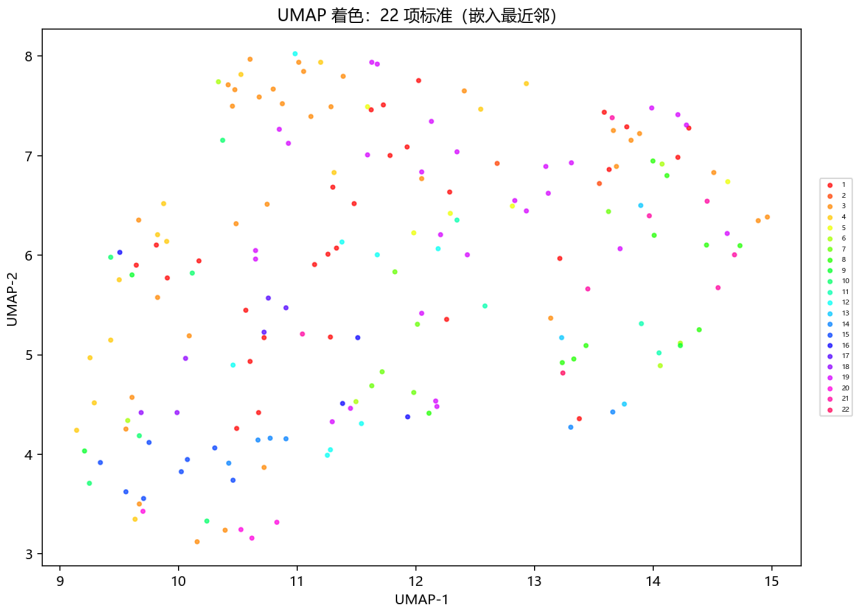

左：句向量 UMAP 后按 **HDBSCAN** 密度簇着色（噪声点为灰）；右：每句在 22 项中取**余弦相似度最大**的一项作为「主色」，用于观察语义是否与合规维度对齐。

可视化：LOFTER —UMAP 与密度聚类、22 项着色

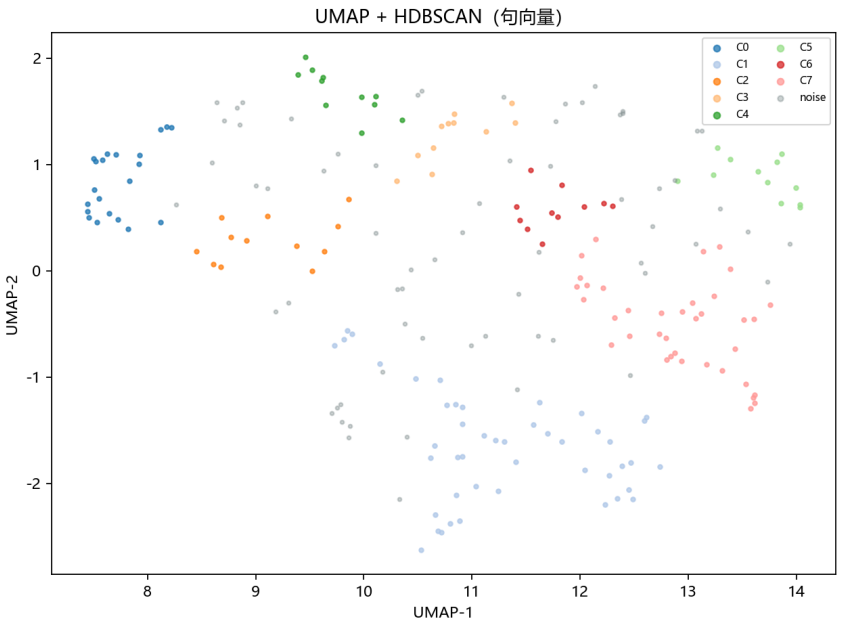

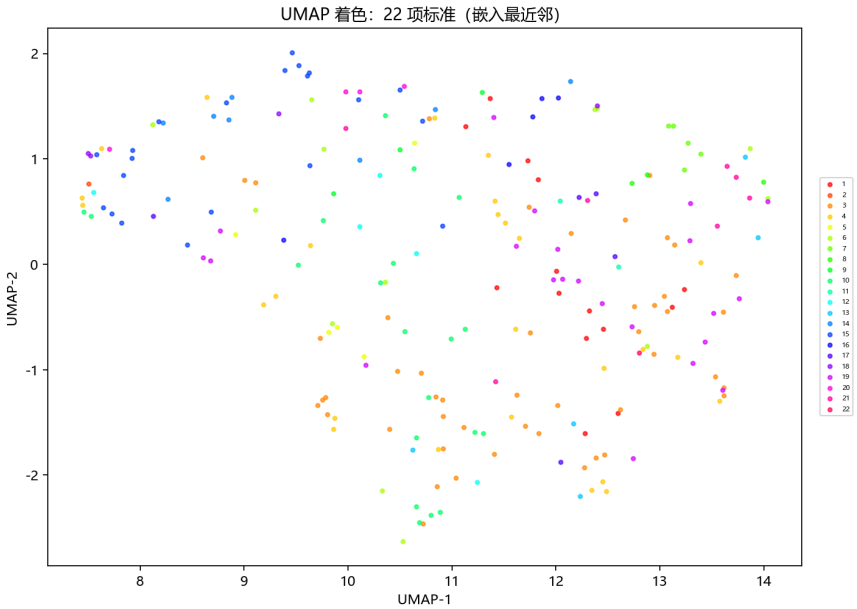

左：句向量 UMAP 后按 **HDBSCAN** 密度簇着色（噪声点为灰）；右：每句在 22 项中取**余弦相似度最大**的一项作为「主色」，用于观察语义是否与合规维度对齐。

可视化：世纪佳缘—UMAP 与密度聚类、22 项着色

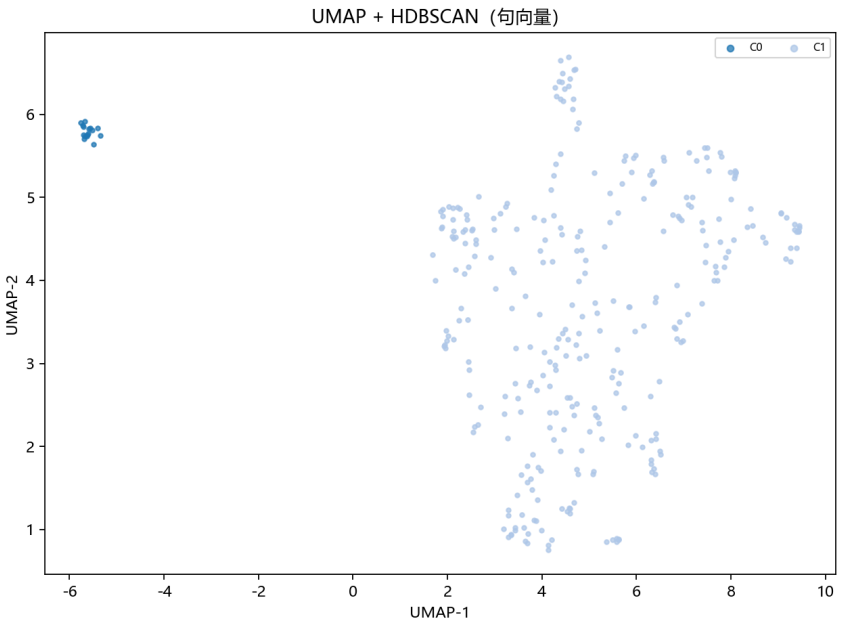

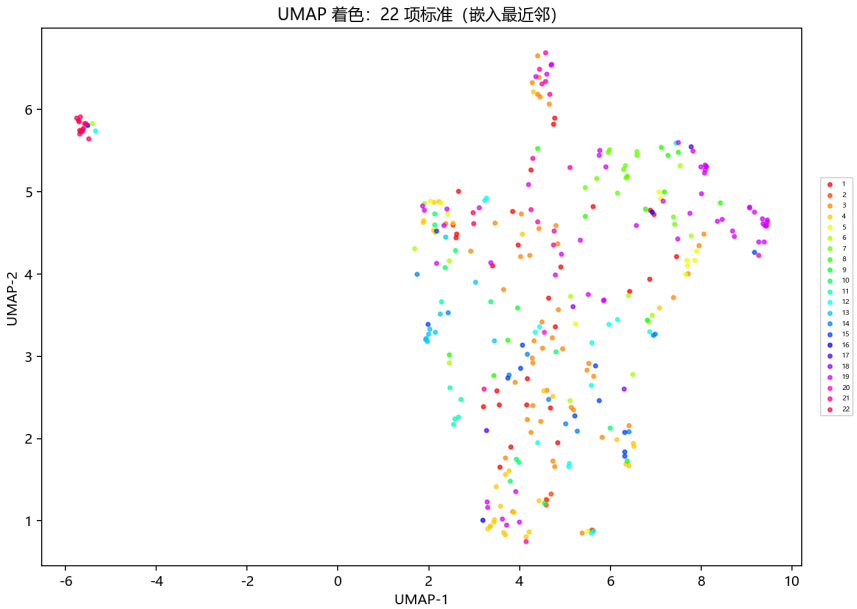

左：句向量 UMAP 后按 **HDBSCAN** 密度簇着色（噪声点为灰）；右：每句在 22 项中取**余弦相似度最大**的一项作为「主色」，用于观察语义是否与合规维度对齐。

可视化：小红书—UMAP 与密度聚类、22 项着色

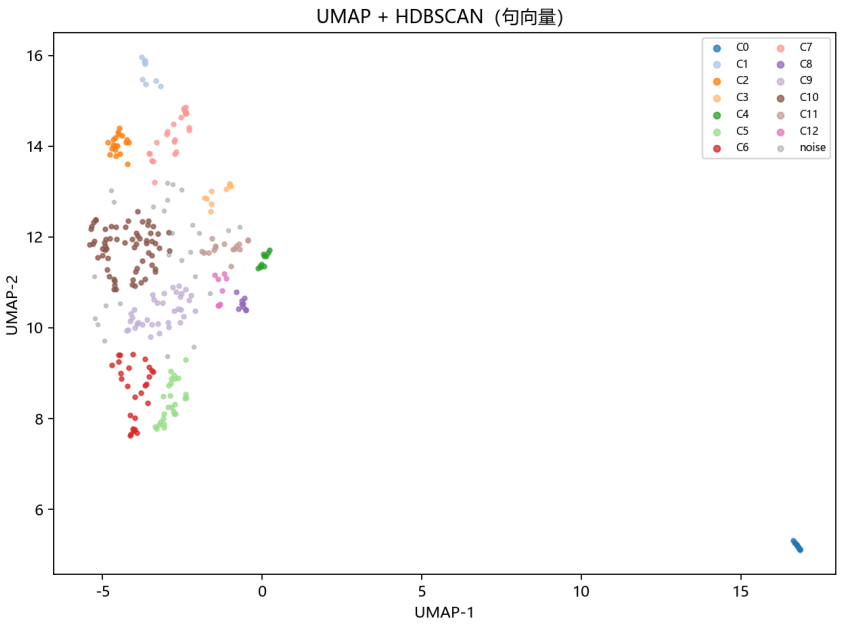

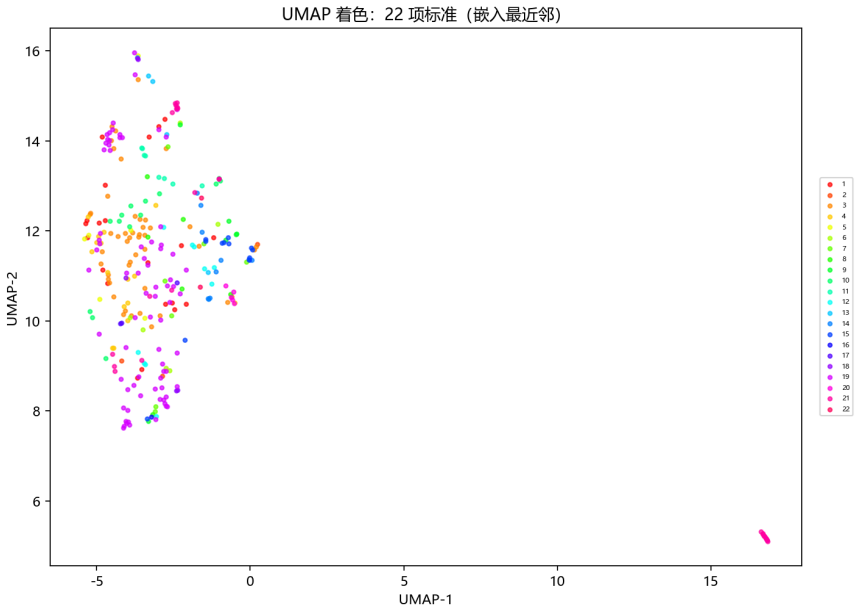

左：句向量 UMAP 后按 **HDBSCAN** 密度簇着色（噪声点为灰）；右：每句在 22 项中取**余弦相似度最大**的一项作为「主色」，用于观察语义是否与合规维度对齐。

22 项合组 UMAP：多种聚合方案

- **内容交叉合组**（各应用页**上排左图**）：**核心告知与行权路径** {2,3,5,6,7,8}；**特定告知与单独同意** {9,10,14,20}；**决策透明与用户控制** {13,8,22}。同一合组内各分点**同色**；灰色为最近邻项不在上述并集内（如项 1、4、11–12、15–19、21 等）。
- **格式 / 核心 / 增强**（各应用页**上排右图**）：**格式与可执行性基础** {17,18,19,21,22}；**核心告知义务** {1–8}；**增强告知与特殊程序义务** {9–16,20}。三组**互斥覆盖** 1–22（与上一种交叉视角不同）。
- **重叠项处理**：仅「内容交叉」方案中 8、22 等跨定义时按**先列出的合组优先**；「格式/核心/增强」与**六分（数据驱动）**各自内部无歧义重叠。
- **实现要点**：句向量 → UMAP 二维坐标；每句对 22 项的相似度来自**句向量与法参考段向量的余弦相似度**；合组图在统一配色规则下**按应用批量出图**便于对照。

六分命名大类：22 项归属表

命名大类	所含标准序号（简要主题）
信息处理基础与台账	**2, 5, 18, 19** —处理目的/方式/种类/期限与查阅复制；真实准确完整；公开便于查阅保存
用户控制与算法交互核心	**7, 8, 13, 21** —删除权、撤回同意；自动化决策；与产品界面联动
未成年人保护专项	**11** —不满 14 周岁未成年人信息
高风险场景及单独同意	**9, 14, 15, 20** —敏感个人信息；公开披露；已公开信息处理；取得同意的规范
主体告知与复合程序要求	**1, 3, 4, 6, 10, 12, 16, 17** —身份联系方式、行权程序、其他法定事项、更正补充、出境、委托/共同/转移、泄露应急、显著清晰
撤回同意便捷性专项	**22** —撤回与取得同意同等便捷

合组 UMAP：Blued 极速版

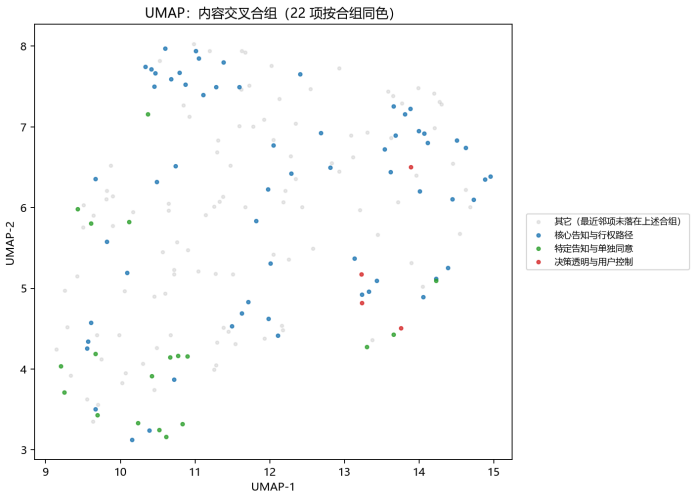

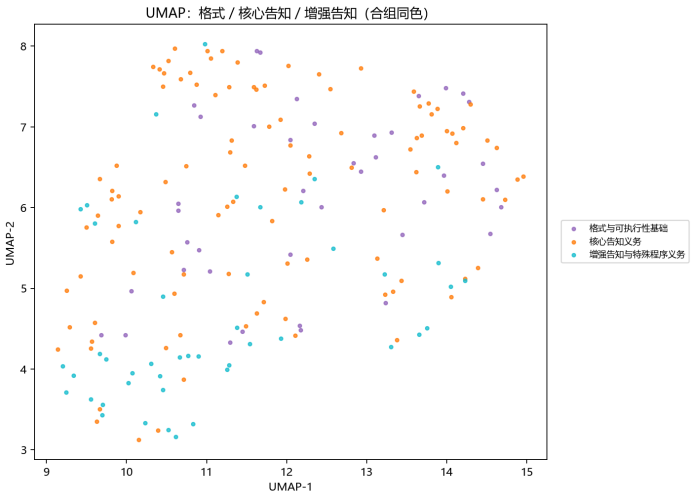

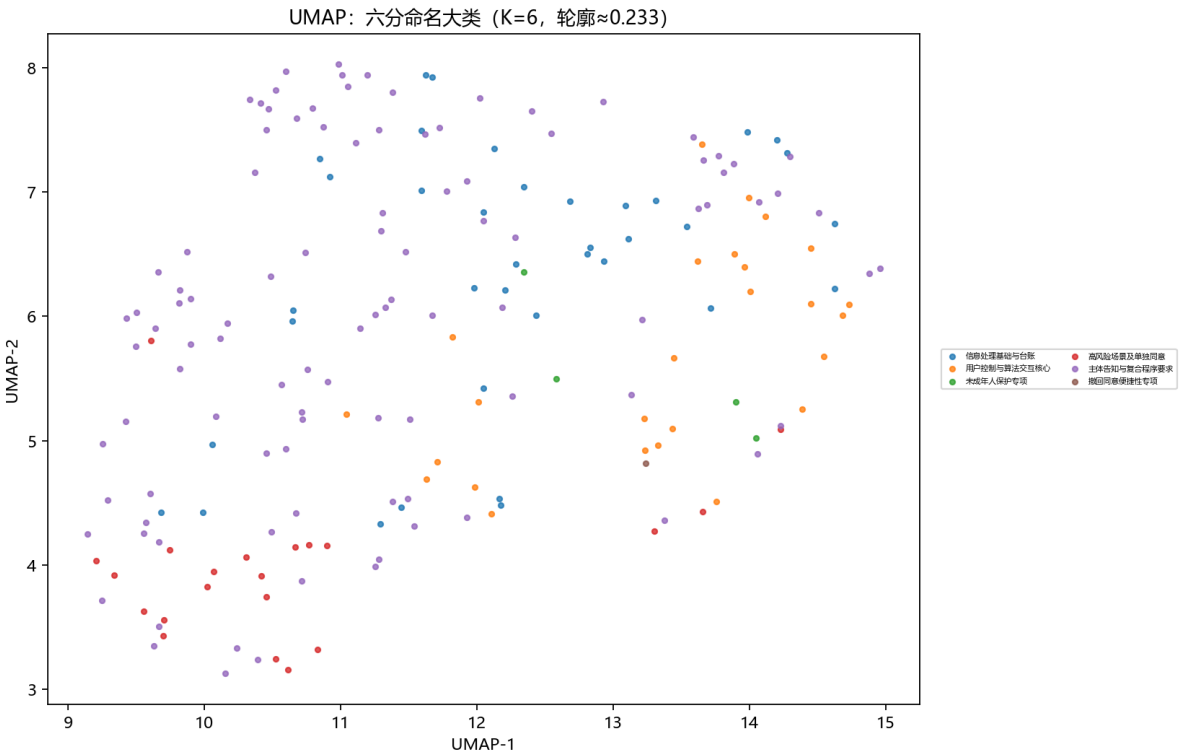

合组 UMAP：LOFTER

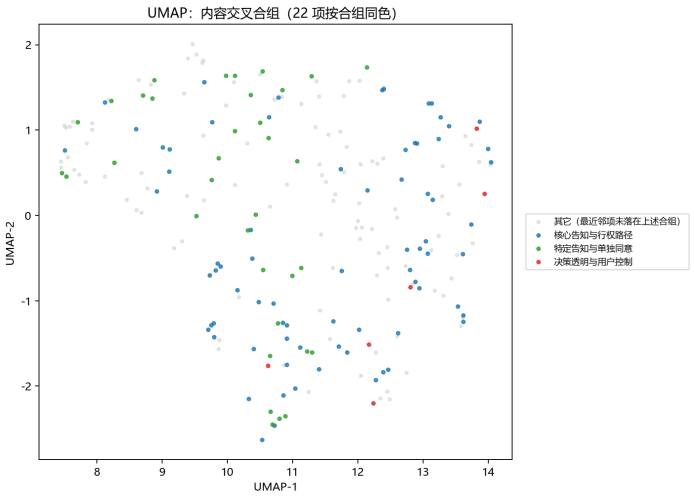

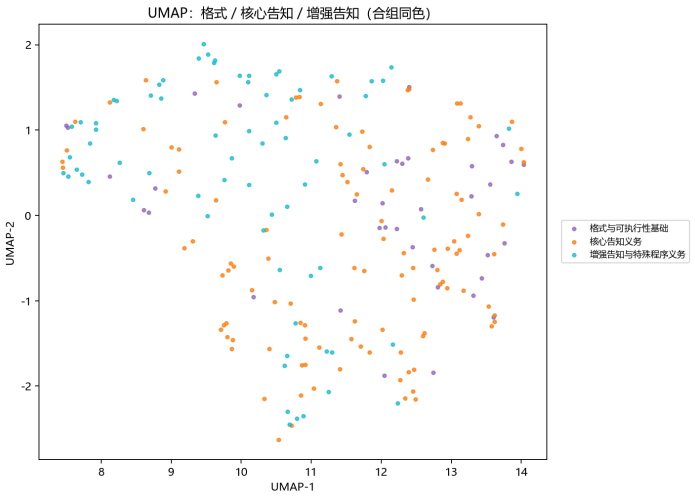

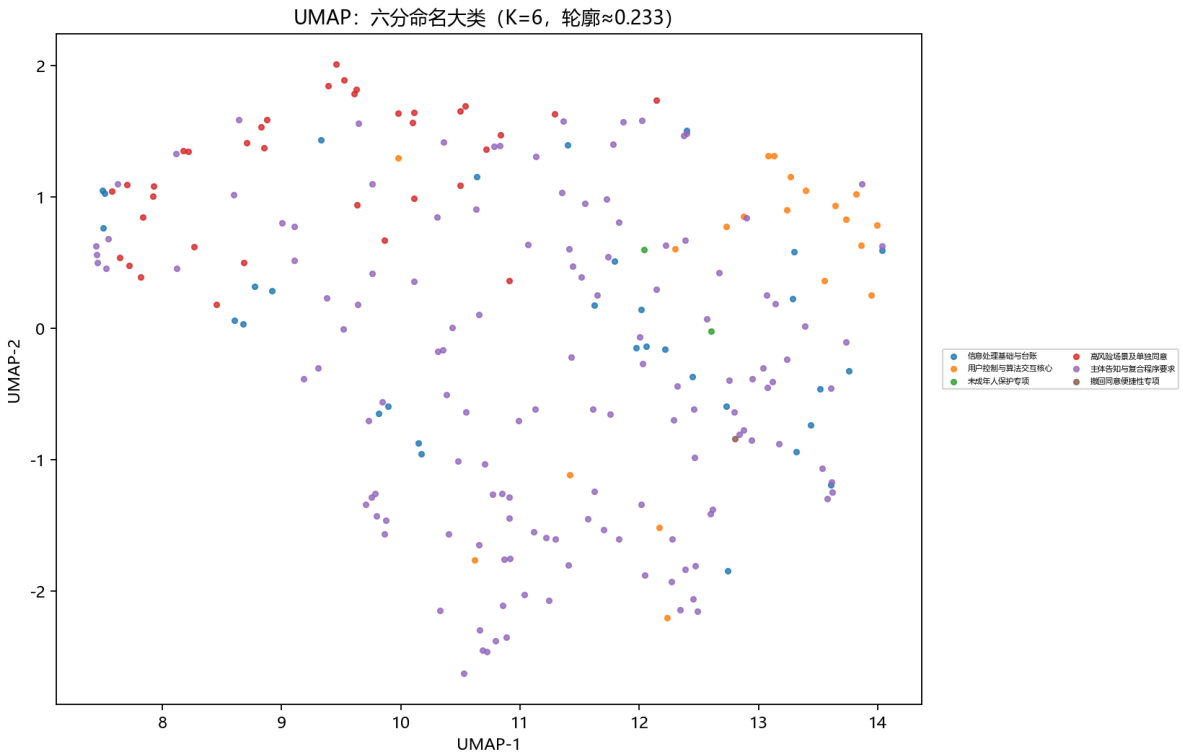

合组 UMAP：Soul

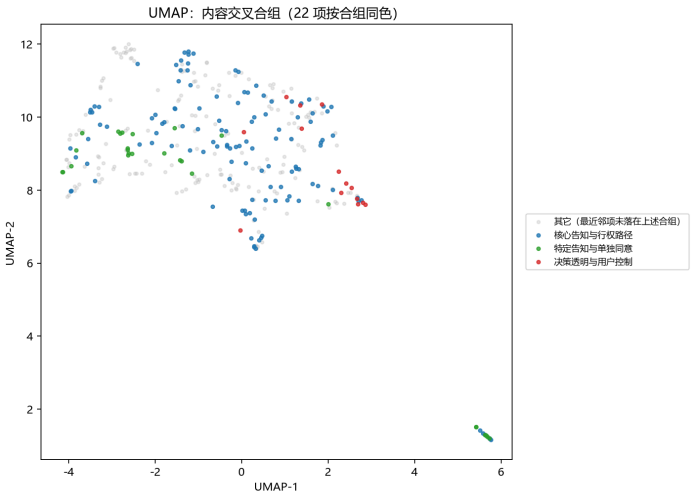
UMAP：内容交叉合组（22 项按合组同色）
UMAP-1
UMAP-2
其它（最近邻项未落在上述合组）
核心告知与行权路径
特定告知与单独同意
决策透明与用户控制

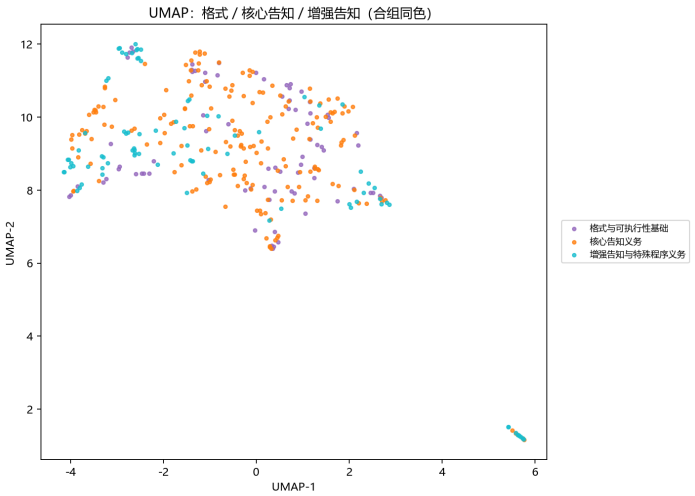
UMAP：格式 / 核心告知 / 增强告知（合组同色）
UMAP-1
UMAP-2
格式与可执行性基础
核心告知义务
增强告知与特殊程序义务

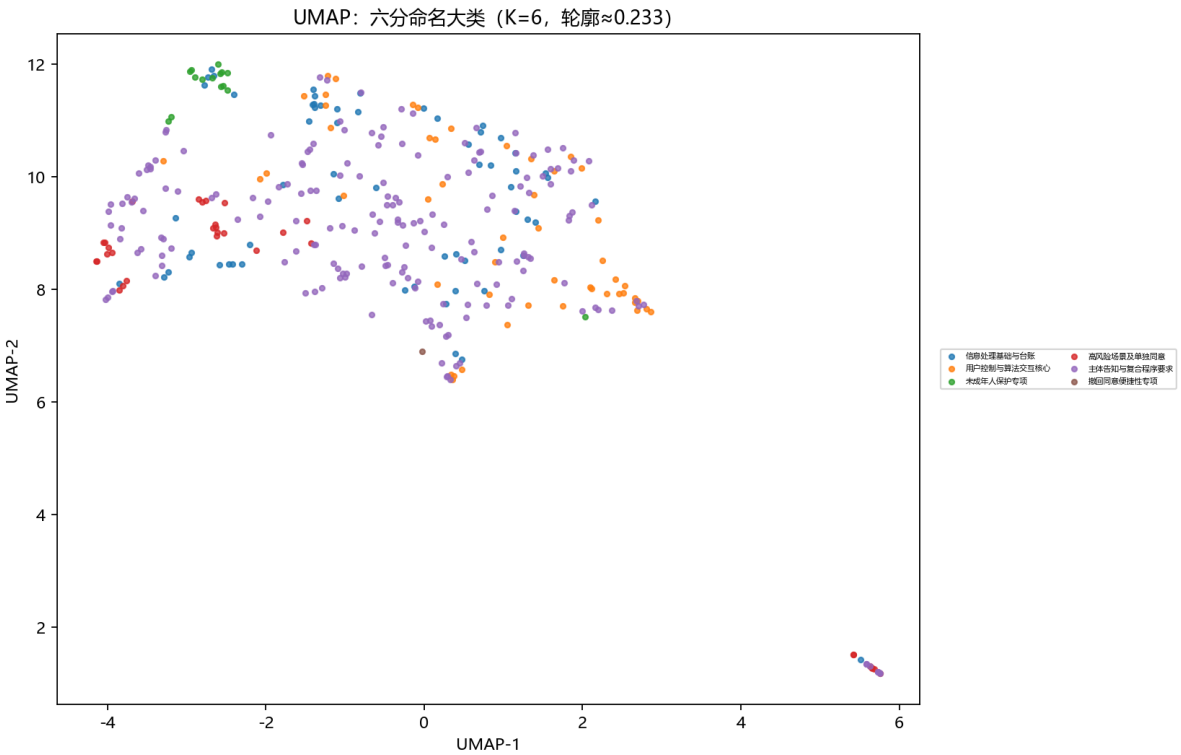
UMAP：六分命名大类（K=6，轮廓≈0.233）
UMAP-1
UMAP-2
信息处理基础与台账
用户控制与算法交互核心
未成年人保护专项
高风险场景及单独同意
主体告知与复合程序要求
撤回同意便捷性专项

合组 UMAP：世纪佳缘

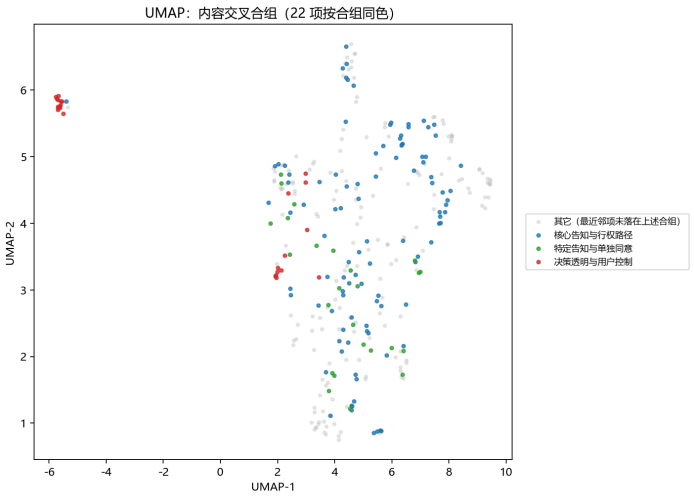
UMAP：内容交叉合组（22 项按合组同色）
UMAP-1
UMAP-2
其它（最近邻项未落在上述合组）
核心告知与行权路径
特定告知与单独同意
决策透明与用户控制

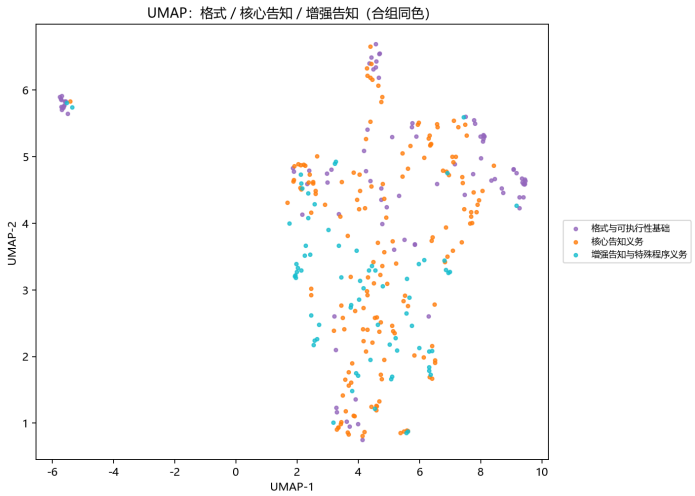
UMAP：格式 / 核心告知 / 增强告知（合组同色）
UMAP-1
UMAP-2
格式与可执行性基础
核心告知义务
增强告知与特殊程序义务

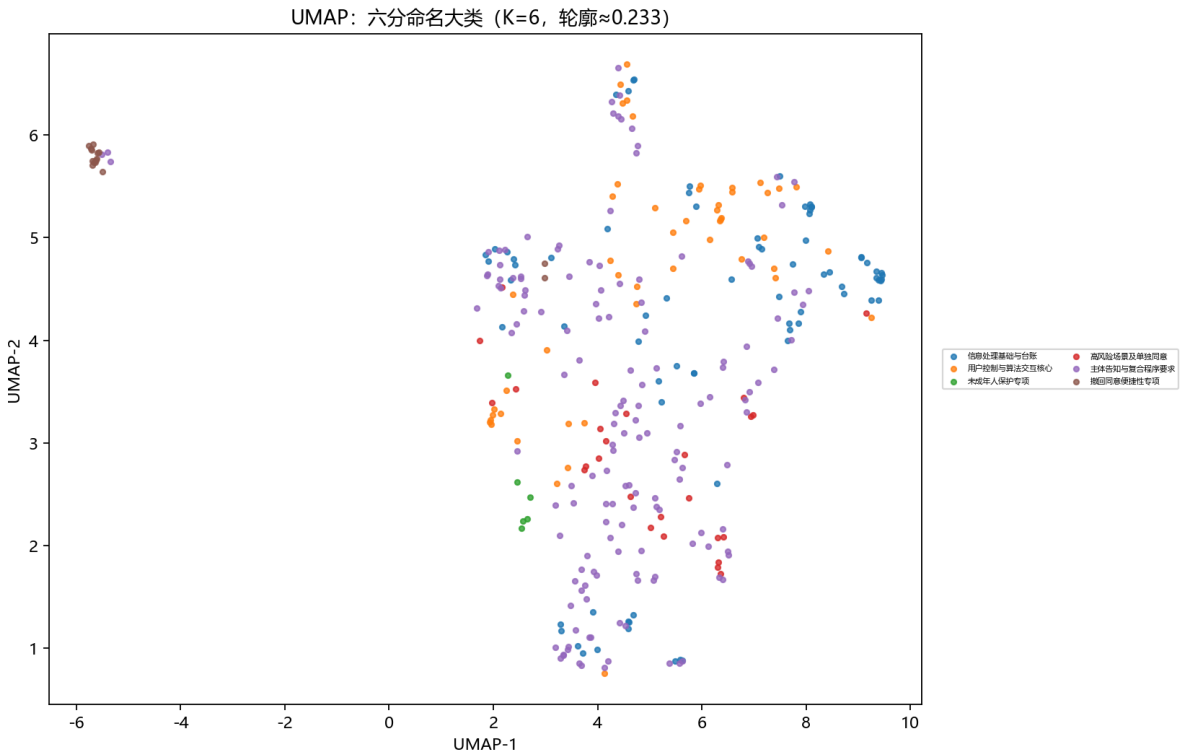
UMAP：六分命名大类（K=6，轮廓≈0.233）
UMAP-1
UMAP-2
信息处理基础与台账
用户控制与算法交互核心
未成年人保护专项
高风险场景及单独同意
主体告知与复合程序要求
撤回同意便捷性专项

合组 UMAP：小红书

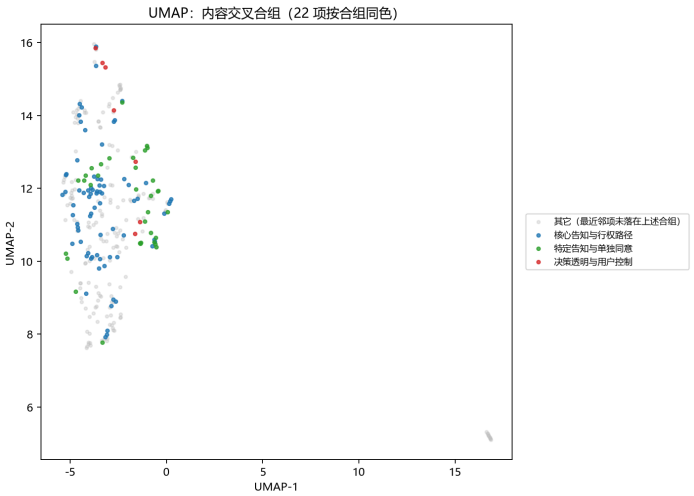
UMAP：内容交叉合组（22 项按合组同色）
UMAP-1
UMAP-2
其它（最近邻项未落在上述合组）
核心告知与行权路径
特定告知与单独同意
决策透明与用户控制

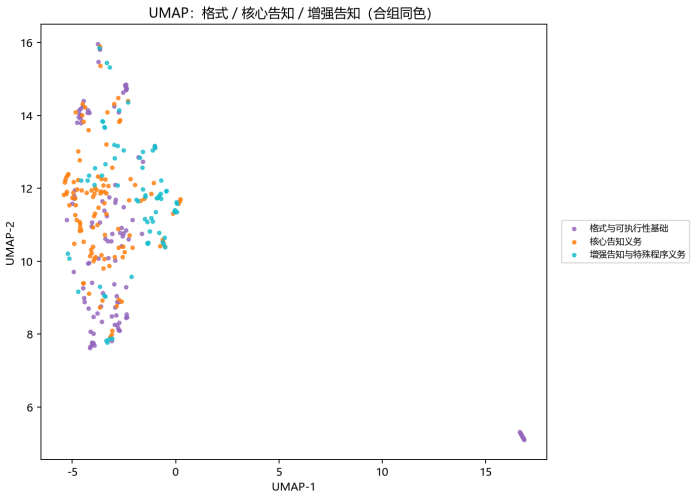
UMAP：格式 / 核心告知 / 增强告知（合组同色）
UMAP-1
UMAP-2
格式与可执行性基础
核心告知义务
增强告知与特殊程序义务

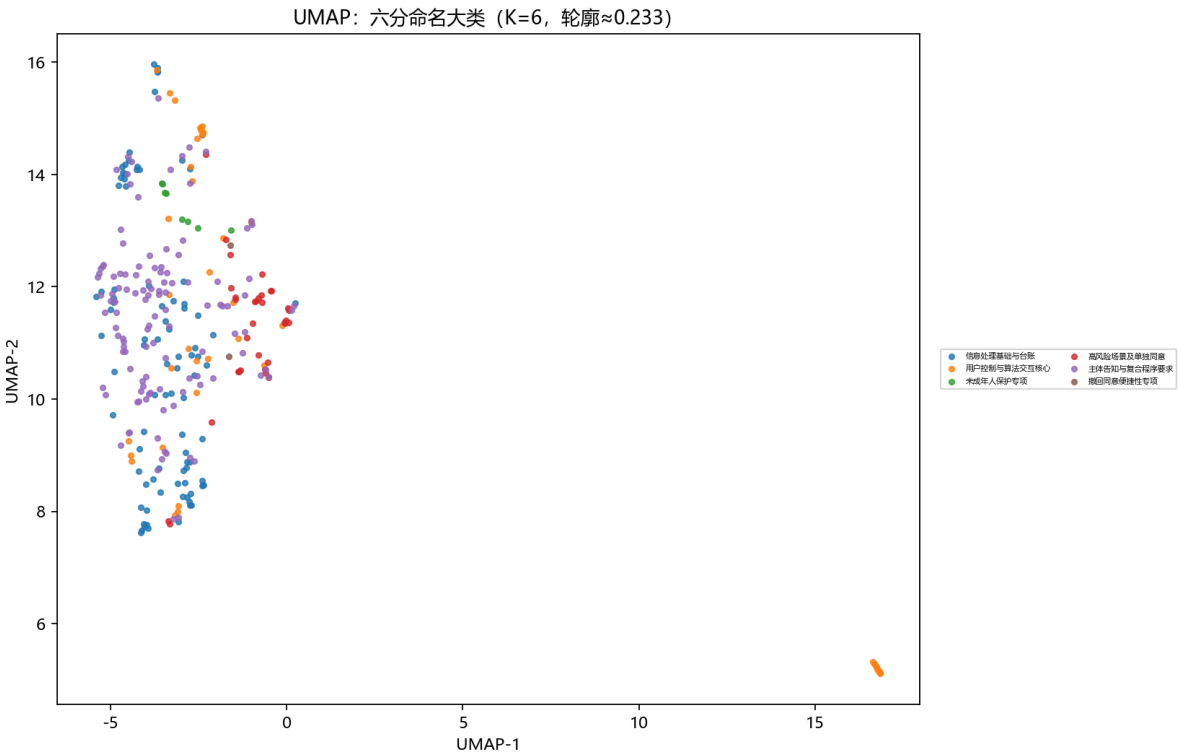
UMAP：六分命名大类（K=6，轮廓≈0.233）
UMAP-1
UMAP-2
信息处理基础与台账
用户控制与算法交互核心
未成年人保护专项
高风险场景及单独同意
主体告知与复合程序要求
撤回同意便捷性专项

可视化：Soul —审计优先级与三标签正例图

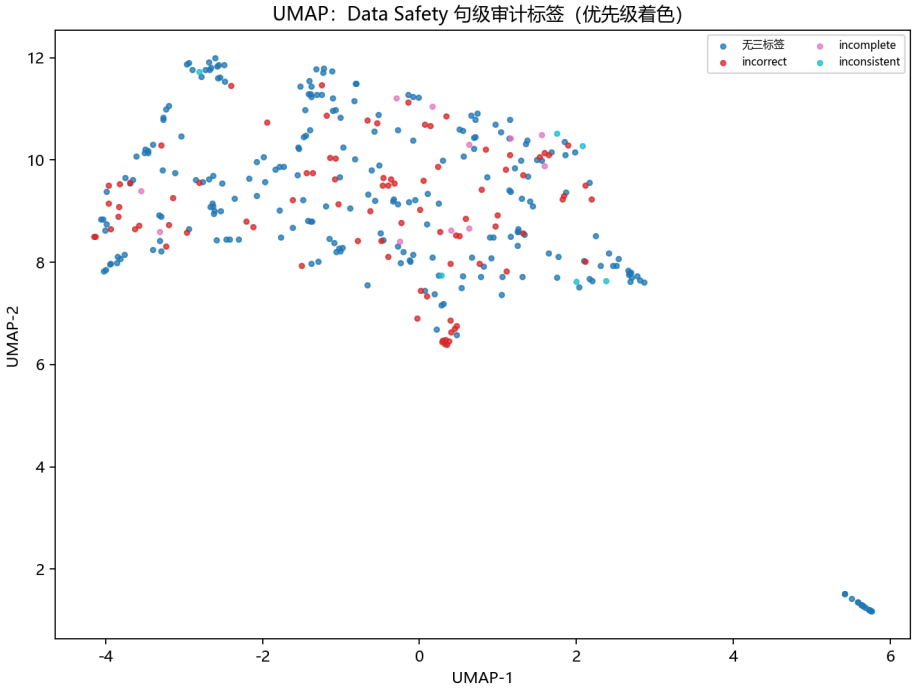

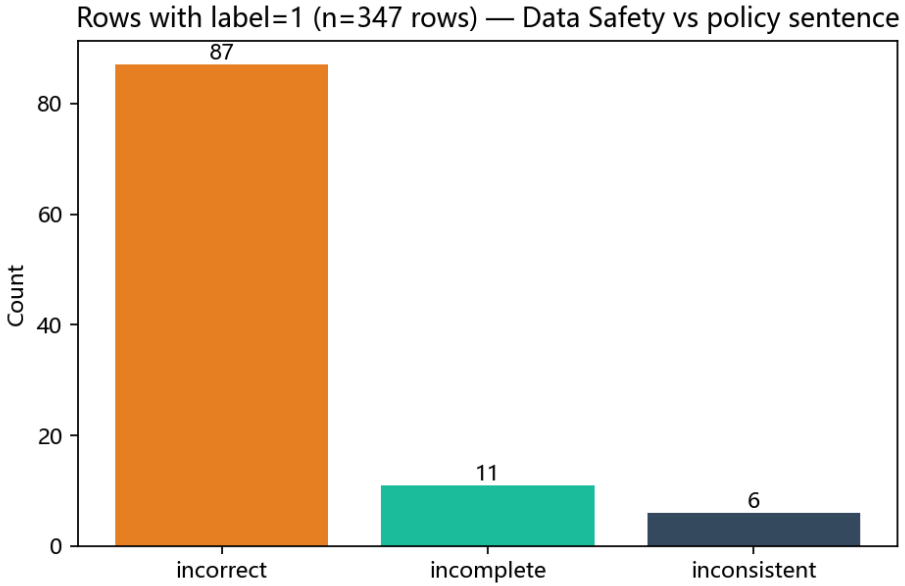

左：按审计优先级着色（无三标签 / incorrect / incomplete / inconsistent）；右：**该应用全量审计结果**上各 Data Safety 标签取**正例**的句数柱状图（非送标抽样）。

可视化：全量句级审计（一）—各应用三标签正例计数

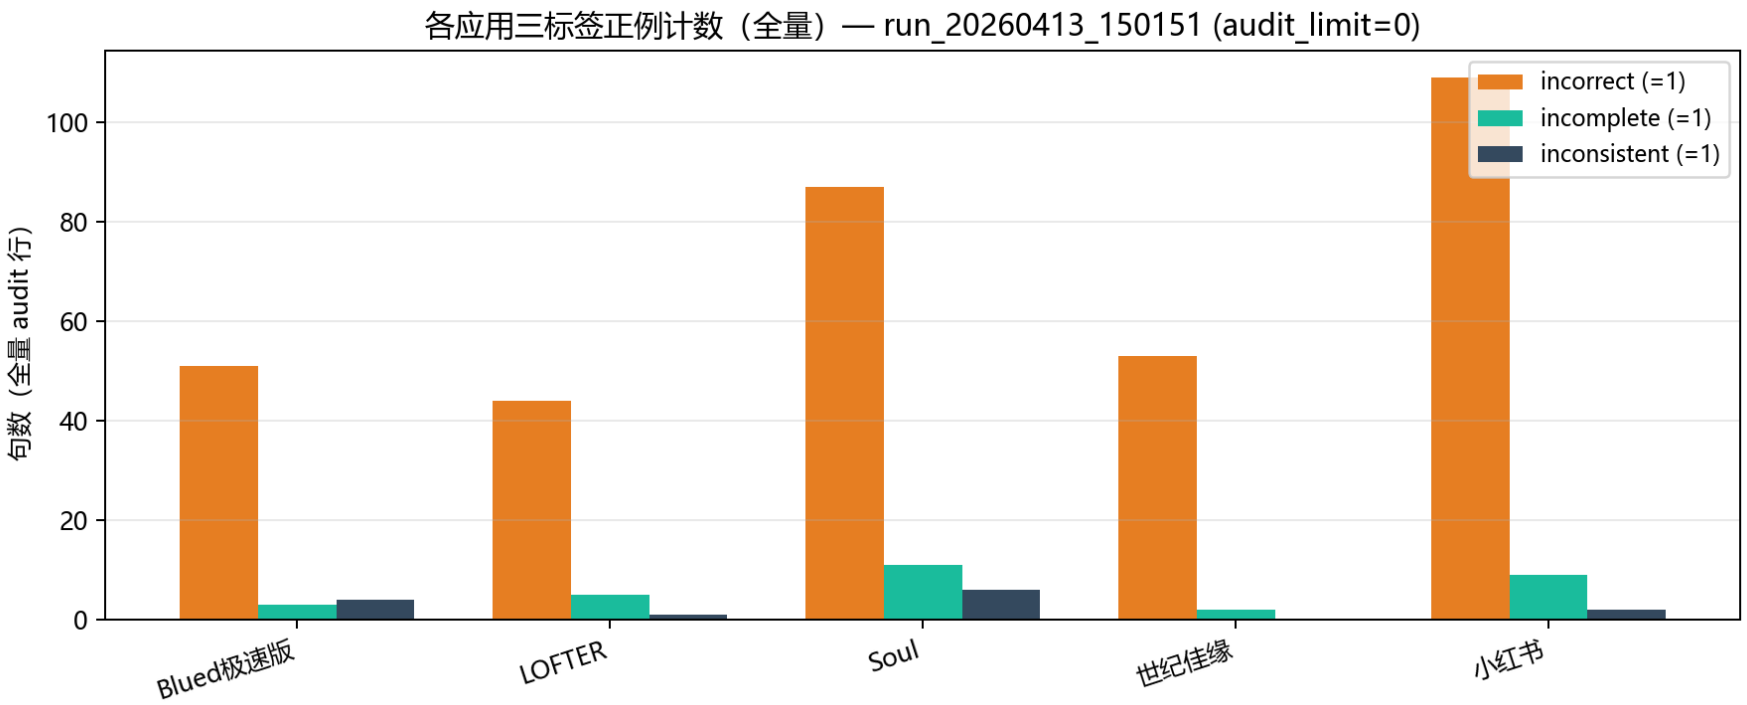

由五应用**全量句级审计表**汇总得到各应用三标签正例计数（分组柱状图）。

可视化：全量句级审计（二）—正例率与全库合计

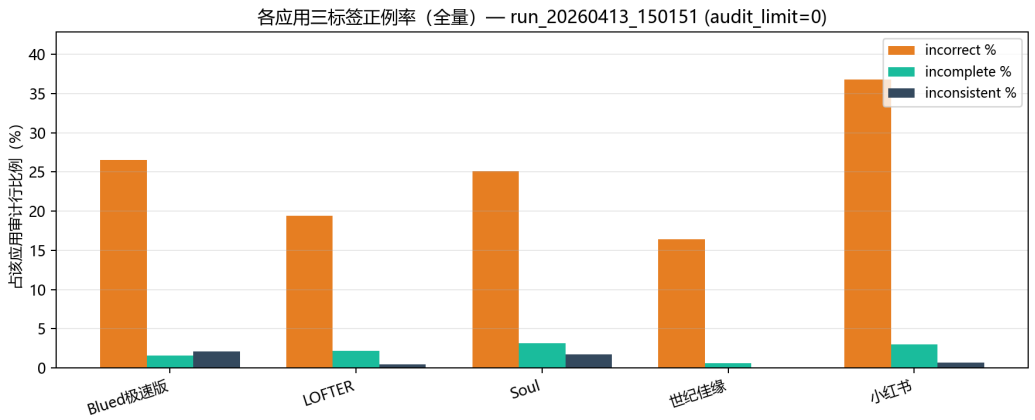

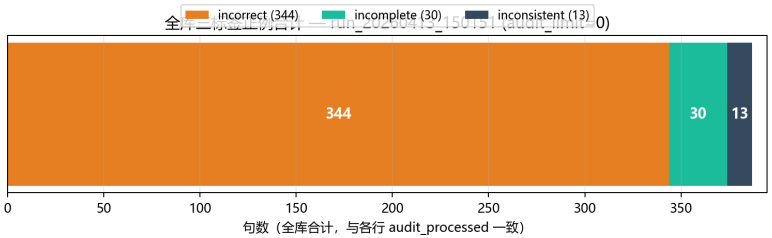

左：各标签正例占该应用**全量审计句**的比例；右：五应用合并后三标签正例句数（**344 + 30 + 13**，与结果表一致）。

感谢聆听！